Maskinlæringsoppgave 2

“Kollideringen mellom Titanic og isberget, hvem overlever?”

Laget av Gruppe 17
Torstein Tønnessen Totland
Sander Rasmussen Nordtvedt
Erik Sædberg Wold
30/10/2026

1. Problembeskrivelse

1.1 Omfang

Formålet med prosjektet vårt er å oppnå, ved hjelp av maskinlæring, en bedre historisk forståelse av Titanic-katastrofen. Gjennom analyser av passasjerenes individuelle attributter, som alder, kjønn og billettklasse, ønsker vi å undersøke hvilke faktorer som styrker sannsynligheten for overlevelse. Dette kan være relevant for historikere som ønsker å utforske sammenhenger mellom individuelle egenskaper og utfallet av katastrofen.

For dette tilfellet vil maskinlæring være en god løsning, gitt modellen kan analysere flere variabler samtidig. Den vil òg kunne vektlegge identifisering av mønstre og sammenhenger ut ifra historisk data. Modellen kan bidra til å utfordre eller underbygge tidligere oppfatninger om hvilke faktorer som påvirket overlevelsesraten. Løsningen vil kunne brukes for å predikere sannsynligheten for overlevelse, basert på opplysninger om den enkelte passasjeren.

Historisk sett har katastrofen blitt undersøkt gjennom vitneforklaringer, dokumentasjon og omfattende forskning. Eksisterende analyser kan også brukes til å undersøke overlevelsesmønstre. Oppgaven, uten maskinlæring, er trolig blitt løst manuelt ved å gjennomgå passasjerlister, sammenligne overlevelsesstatistikk og å undersøke hvilke grupper som hadde størst sannsynlighet for å overleve. Prinsipp som “kvinner og barn først”, eller forskjeller på billettklassene, kan ha utspilt en faktor for sjansen til å overleve.

Ved å benytte maskinlæring ønsker vi å undersøke disse sammenhengene på en mer systematisk måte. Dette kan bidra til å vurdere hvor godt en modell kan predikere overlevelse, basert på tilgjengelige historiske data.

1.2 Metrikker

For å vurdere hvor godt maskinlæringsmodellen fungerer, benytter vi oss av treffsikkerhet som hovedmetrikken. Dette måler hvor stor andel av passasjerene, modellen klarer å klassifisere riktig, basert på de som overlevde. Vil vil også vurdere presisjon og recall, for å få en bedre forståelse av modellens prediksjon. Presisjon viser hvor stor andel av passasjerene som modellen vil overleve, som faktisk overlevde. Recall vil derimot vise hvor stor andel av de som faktisk overlevde, som modellen klarer å identifisere.

Modellens ytelse evalueres på testdata som ikke har blitt brukt under treningen. Det gjør det mulig å undersøke hvor godt modellen generaliserer til nye data, fremfor å kun gjenkjenne mønstre fra treningsdatasettet.

Et mål vi setter for modellen, er at den skal oppnå en treffsikkerhet på minst 80%. Dette gir et utgangspunkt som lar oss vurdere om modellen får til å identifisere relevante sammenhenger mellom passasjerens individuelle egenskaper og sannsynlighet for overlevelse.

Gitt prosjektet vårt primært har et historisk analytisk formål, vil vi ikke ta i bruk kommersielle metrikker som lønnsomhet eller antall brukere. Prosjektets suksess vil i stedet vurderes ut fra modellens prediksjonsevne og hva betydning resultatene, vil bidra til en bedre forståelse av faktorene som påvirker overlevelse under synkingen.

2. DATA

Prosjektet bruker Titanic - Machine learning from disaster(Kaggle. u.å) datasettet for å predikere overlevelsesjansen basert på hva slags attributter en enkelt person på Titanic har. Datasettet inneholder informasjon om passasjerene som alder, kjønn, billettklasse, billettpris, og antall familiemedlemmer om bord. Modellen bruker variablene:

- **Pclass:** Billettklasse (1, 2 eller 3).
- **Sex:** Kjønn (male eller female).
- **Age:** Passasjerens alder.
- **SibSp:** Antall søsken eller ektefeller om bord.
- **Parch:** Antall foreldre eller barn om bord.
- **Fare:** Billettprisen passasjerene betalte.

Variabelen Survived blir brukt som label. Dette er verdien vi skal predikere om stemmer for en vilkårlig passasjer.

- **0:** Passasjeren overlevde ikke.
- **1:** Passasjeren overlevde.

Bruk av labels betyr at vi bruker supervised learning for modellen vår. Det vil si at modellen trenes på data med kjente svar. variabelen survived i vårt eksempel.Vi bruker datasettet Train.csv fra Kaggle (Cukierski, 2012), som inneholder informasjon om 891 passasjerer og om de overlevde Titanic-forliset. Vi deler datasettet i 80 % treningsdata og 20 %

valideringsdata. Treningsdataene brukes til å trene modellen, mens valideringsdataene brukes til å evaluere hvor godt modellen fungerer på passasjerer den ikke har sett tidligere. Kaggle tilbyr også filen test.csv, men denne bruker vi ikke i prosjektet.

Dataen som er gitt i datasettet dekker alle passasjerene. Det er da også ingen måte å få mer data på dette. Om prosjektet skal oppskaleres til flere større båtulykker kunne det blitt en del av et større dataset basert på data gitt fra de andre ulykkene. En viktig en presisering var at det var over 800 mannskap på båten som ikke ble tatt med i datasettet. Vi mangler derfor en stor del av totalt antall mennesker om bord. Dette bør inkluderes for å få et bedre blikk på eventuelle konsekvenser av et havari, dersom denne modellen skulle bli brukt til å støtte et større datasett med båtulykker.

Datasettet inneholder også informasjon om navn, tittel, kabinnummer og hvilken havn de gikk ombord på. Vi har rensket vekk det vi mener ikke var like relevant for modellen og valgte å ekskludere disse.

3. Modellering

Vi bruker Logistic Regression for prediksjonen vår om overlevelsessjansen for Titanic ulykken. Denne modellen egner seg godt til modeller der utfallet har to mulige verdier. I vårt tilfelle har vi verdiene om du overlever eller ikke.

For å vurdere prestasjonen til modellen for vår problemstilling, sammenligner vi den med en baseline laget med DummyClassifier (Pedregosa et al., 2011, #). Denne modellen predikerer den vanligste klassen i treningsdatasettet, som er i vårt tilfelle at passasjeren døde.

DummyClassifier modellen oppnådde en accuracy på 61,45%, mens vårt valg, Logistic Regression, oppnådde 80,45%. Dette tilsvarer en 19 prosentpoeng ledelse til vår modell, noe som tilsier at den gir bedre prediksjoner enn å alltid velge den vanligste klassen.

Vi evaluerer modellen vår med metrikkene accuracy, precision, recall og F1-score. Disse viser oss hvor godt modellen klarer å klassifisere passasjerene, og eventuelle feil, modellen gjør. Resultatene er i tabellen under:

Metrikk	Baseline	Logistic Regression
Accuracy	61.45 %	80.45 %
Precision	0.00 %	76.56 %
Recall	0.00 %	71.01 %
F1-score	0.00 %	73.68 %

Accuracy forteller oss hvor stor andel av prediksjonene er riktige. Modellen oppnådde 80.45%. Det betyr at omtrent 8 av 10 passasjerer ble riktig klassifisert.
Precision forteller oss hvor mange av passasjerene som modellen vår predikerte ville overleve, som faktisk overlevde. Modellen vår oppnådde 76.56% i dette.
Recall forteller oss hvor mange av passasjerene som overlevde, og modellen vår klarte å identifisere. Modellen vår oppnådde 71.01% her, noe som betyr at den ikke klarte å identifisere alle som overlevde.
F1-score er en kombinasjon av precision og recall. Modellen fikk en F1-score på 73.68%, og viser balansen mellom disse metrikkene.
Baselinen viser 0% på de siste tre nevnte fordi den alltid predikerer at passasjerene ikke overlever.
Resultatene viser at Logistic Regression presterer bedre enn baseline på alle metrikkene. Samtidig viser precision og recall at modellen ikke er feilfri, og ikke kan stoles helt på. Dette gjelder spesielt når vi skal identifisere passasjerer som overlever.

For å undersøke nøyaktig hvilken feil modellen gjorde, bruker vi noe som heter confusion matrix. Den viser hvor mange passasjerer modellen klassifiserte riktig og feil.

	Predikert: Ikke overlevd	**Predikert: Overlevd**
Faktisk: Ikke overlevd	95	15
Faktisk: Overlevd	20	49

Av 179 passasjerer i valideringsdataene så klassifiserte modellen 144 riktig og 35 feil. Modellen predikerte at 15 passasjerer hadde overlevd selv om de ikke gjorde det i realiteten. Modellen predikerte også at 20 passasjerer ikke ville overleve, selv om de overlevde i realiteten.

Vi undersøkte også hvordan de ulike variablene vi brukte i Logistic Regression modellen påvirket prediksjonene.

Variabel	**Koeffisient**
Sex	2,6133
Pclass	-1,0510
SibSp	-0,2676
Parch	-0,1023
Age	-0,0386
Fare	0,0032

Kjønn hadde den største positive koeffisienten. Siden kvinner er kodet som verdien 1 og menn som 0, så betyr det at modellen knytter det å være kvinne til høyere sannsynlighet for å overleve.

Billetklasse metrikken hadde en negativ koeffisient. Det betyr at modellen knytter det å ha en lavere billettklasse til å ha en mindre sjanse for å overleve.

Alder og antall familiemedlemmer hadde også negative koeffisienter, mens billettpris hadde en svak positiv koeffisient per billettpris-verdi.

For å gjøre modellen bedre kunne vi ha undersøkt de passasjerene som ble feilklassifisert nærmere. Vi kunne ha testet andre variabler, og vi kunne ha sammenlignet Logistic Regression modellen opp mot andre modeller.

4. Deployment

Hvordan er modellen satt i drift?

Den ferdigtrente modellen er lagret som fil titanic_model.pkl med Joblib i repositoriet, sammen med koden til nettsiden. Både i treningen train.py og i nettsiden app.py blir kjønn gjort om til tall på samme måte, slik at brukerinput får samme behandling som treningsdataen, noe som er nødvendig for at prediksjonene skal bli riktige.

Nettsiden er laget med Gradio og kjøres lokalt. Når den starter, lastes modellen inn én gang og holdes i minnet slik at hver prediksjon går fort.

Flyten for en prediksjon ser slik ut:

1. Brukeren setter inn passasjeropplysningene i skjema. Input er begrenset til drop-down meny for kjønn og klasse, og slidere for numeriske verdier. Dette hindrer ugyldige inputs og dermed også feilhåndtering.
2. Dataene gjøres om til samme format som treningsdataen og sendes til modellen.
3. Modellen returnerer sannsynligheten for at personen overlever og for at personen omkommer, og nettsiden viser begge sammen med en konklusjon.

Hvordan brukes prediksjonene?

Konklusjonen bestemmes av hvilken av de to sannsynlighetene som er høyest, som vil si en terskel på 50%. Vi viser sannsynlighetene i tillegg til konklusjonen for å gi et tydeligere bilde enn et rent ja/nei svar. En prediksjon på 51% er veldig forskjellig fra en på 95%, selv om de har gitt samme konklusjon. Applikasjonen sier ikke noe om enkeltpersoner, men er heller ment for formidling og læring.

Monitoring og vedlikehold

Modellen er trent én gang på et lukket datasett. Skipet sank for over hundre år siden, så vi antar det ikke kommer nye passasjerer. Dermed er det ikke behov for å trene modellen på nytt. Det eneste vedlikeholdet vil da være å holde nettsiden oppe og at bibliotekene den bruker skal fungere.

Videre forbedringer

Modellen kan testes med flere variabler fra datasettet, som påstigningshavn og tittel fra navnet(Mr,Mrs, Ms, Master), som vi tror vil ha en tydelig endring blant unge menn kontra gutter/barn.

5. Referanser

Cukierski, W. (2012). *Titanic - Machine Learning from Disaster*. Titanic - Machine Learning from Disaster | Kaggle. Retrieved October 25, 2026, from https://www.kaggle.com/competitions/titanic/data

Gradio API Documentation. (n.d.). Gradio. Retrieved October 25, 2026, from https://www.gradio.app/docs

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825. https://jmlr.csail.mit.edu/papers/v12/pedregosa11a.html